


Лабораторная работа 1.

Загрузка данных в S3-совместимое хранилище MinIO, чтение и анализ данных

Цель работы: научиться собирать небольшой, но реальный **Data Pipeline**: от исходного файла до объектного хранилища и аналитического набора данных.

Общая структура работы




Parquet –открытый колоночный формат хранения структурированных данных, оптимизированный для эффективной обработки больших объемов данных.

S3 (Simple Storage Service) - стандарт облачного объектного хранения данных, созданный компанией Amazon Web Services.

MinIO –объектное хранилище данных с открытым исходным кодом, совместимое с Amazon S3 API.

Структура объектного хранилища



- **Bucket** — логический контейнер для объектов;
- **Object** — файл — основная единица хранения;
- raw/ processed/ analytics/ — логические префиксы, похожие на папки.

MinIO хранит файлы как объекты, а Parquet определяет формат, в котором данные находятся внутри файла.

Требования к инфраструктуре

На компьютере должны быть установлены и настроены:


1. Python версии 3.11 или 3.12
2. Для Python должны быть установлены библиотеки:
pandas, pyarrow, boto3, s3fs

Библиотека	Назначение
pandas	Чтение и обработка данных
pyarrow	Работа с форматом Parquet
boto3	Подключение к S3 API / MinIO
s3fs	Доступ к S3 как к файловой системе через Pandas

3. VS Code + расширение Python для написания и запуска Python-кода
4. Docker Desktop
5. MinIO, установленное и запущенное локально через Docker

Все манипуляции с данными выполняются с помощью Python.

Рекомендуемая структура проекта в GIT.



Выполнение работы

1. Подготовка csv-файла

В качестве примера рассматривается файл students.csv.

student_id	name	course	score
1	Анна Иванова	Инженерия данных	195
2	Борис Фролов	Python	182
3	Мария Кузьмина	Инженерия данных	191
4	Иван Петров	SQL	176
5	Елена Мартынова	Python	168
6	Алексей Смирнов	Инженерия данных	188
7	Ольга Соколова	SQL	193
8	Дмитрий Волков	Python	179
9	Наталья Орлова	Инженерия данных	185
10	Сергей Морозов	SQL	190
11	Татьяна Белова	Python	187
12	Максим Козлов	Инженерия данных	172
13	Екатерина Новикова	SQL	196
14	Андрей Васильев	Python	184
15	Светлана Павлова	Инженерия данных	189
16	Михаил Захаров	SQL	168
17	Юлия Романова	Python	194
18	Виктор Егоров	Инженерия данных	181
19	Дарья Никитина	SQL	177
20	Кирилл Федоров	Python	192

2. Чтение CSV и сохранение данных в формате Parquet

С этой целью можно использовать функции `read_csv` и `to_parquet` библиотеки `pandas`.

`Pandas` — это библиотека с открытым исходным кодом, которая предлагает широкий спектр инструментов для обработки и анализа данных. С ее помощью можно читать данные из широкого спектра источников, таких как CSV, JSON и Excel.

Обычно при импорте библиотеке назначают псевдоним `pd`:

```
import pandas as pd
```

DataFrame - это наиболее часто используемый класс pandas для обработки данных. Это двумерная структура данных, которая хранит данные в виде двумерного массива или таблицы со строками и столбцами потенциально разных типов..

Переменная df класса DataFrame используется в функциях read_csv и to_parket.

Пример кода:

```
import pandas as pd
df = pd.read_csv('students.csv')
df.to_parquet(
    "students.parquet",
    index=False)
```

В результате в локальной папке должен быть создан файл "students.parquet".

3. Подключение к хранилищу MinIO

Для работы с S3 API используется библиотека boto3.

Пример кода:

```
import boto3

s3 = boto3.client(
    "s3",
    endpoint_url="http://localhost:9000",
    aws_access_key_id="admin",
    aws_secret_access_key="password"
)
```

В качестве access_key_id и aws_secret_access_key передаются те же данные, которые были заданы при настройке процесса MinIO в Docker.

Далее необходимо создать bucket, например . "university-data"

Пример кода:

```
bucket_name = "university-data"

s3.create_bucket(
    Bucket=bucket_name)
response = s3.list_buckets()
```

Для проверки можно вывести список bucket в хранилище.

Пример кода:

```
for bucket in response["Buckets"]:
    print(bucket["Name"])
```

Ожидаемый результат:

university-data

4. Загрузка данных в MinIO


Файлы в csv и parquet необходимо загрузить в хранилище MinIO, указав в функции `upload_file` название bucket и соответствующие префиксы.

Пример кода:

```
import boto3
s3 = boto3.client(
    "s3",
    endpoint_url="http://localhost:9000",
    aws_access_key_id="admin",
    aws_secret_access_key="password"
)
s3.upload_file(
    "students.csv",
    "university-data",
    "raw/students.csv"
)

s3.upload_file(
    "students.parquet",
    "university-data",
    "processed/students.parquet"
)
```

В результате хранилище приобретает следующую структуру.



5. Чтение Parquet из MinIO в DataFrame

Еще один способ работы с S3-хранилищем – использование библиотеки `s3fs`.

В качестве key и secret_key также передаются данные, которые были заданы при настройке процесса MinIO в Docker.

```
import s3fs
import pandas as pd

storage_options = {
    "key": "admin",
    "secret": "password",
    "client_kwargs": {
        "endpoint_url": "http://localhost:9000"
    }
}

df_from_minio = pd.read_parquet(
    "s3://university-data/processed/students.parquet",
    storage_options=storage_options
)
```

Таким образом, данные для анализа можно получить автоматизировано, не скачивая их предварительно вручную через браузер.

6. Анализ данных

С помощью библиотек Python (pandas, pyarrow) можно выполнить небольшой анализ данных непосредственно в формате Parquet, не загружая их в БД и не выполняя SQL-запросов.

Группировка и расчет среднего. Пример кода:

```
result=df_from_minio.groupby(
    "course"
)["score"].mean()
print(result)
```

Фильтрация по рейтингу. Пример кода:

```
result=df_from_minio[
    df_from_minio["score"] >= 190
]
print(result)
```

Группировка по курсу и расчет агрегирующих показателей.

Функция agg() позволяет запустить несколько разных расчетов (сумму, среднее, минимум, максимум) для разных столбцов за один раз.

Пример кода:

```
result = (
    df_from_minio
```

```
.groupby("course")
.agg(
    average_score=("score", "mean"),
    students_count=("student_id", "count")
)
.reset_index()
)
```

Результаты анализа можно записать в формате Parquet в объектное хранилище.

```
result.to_parquet(
    "s3://university-data/analytics/course_statistics.parquet",
    storage_options=storage_options
)
```

Результат работы

Отчет по лабораторной работе должен содержать:

1. Исходные данные;
2. Parquet-файл;
3. Свой bucket, созданный в хранилище MinIO;
4. Структуру `raw/`, `processed/`, `analytics/`;
5. Код загрузки;
6. Код чтения;
7. Небольшой аналитический итог – код и результат.